

ESTUDIO COMPARATIVO DE ESQUEMAS DE CONTROL INTELIGENTE APLICADO A UN TANQUE CON AGITACION CONTINUA

Mario A. Muñoz, Eduardo F. Caicedo, Jesús A. López

*Grupo de Investigación en Percepción y Sistemas Inteligentes
Escuela de Ingeniería Eléctrica y Electrónica
Universidad del Valle, Cali, Colombia
e-mail: {andremun,ecaicedo,jesuslop}@univalle.edu.co*

Resumen: En este trabajo se estudia la simulación de controladores neuronales, difusos y PID sintonizado evolutivamente para un tanque de calentamiento de agitación continua; y se presenta un análisis comparativo del desempeño de los mismos. Los resultados demostraron la factibilidad y el funcionamiento adecuado de ciertos controles para esta planta y las dificultades que se podrían presentar en la implementación de uno u otro para este caso. El trabajo pretende demostrar la utilidad de estos métodos gracias a su flexibilidad y a la posibilidad de implementar controladores a plantas cuyo modelo matemático exacto se desconoce.

Keywords: Control system design, Fuzzy Control, Intelligent Control, Model-based control, Neural Networks Models, Neural control

1. INTRODUCCIÓN

Diseñar controladores que no requieran un exhaustivo trabajo matemático es uno de los problemas que posee la teoría de control. La sintonización de controladores del tipo PID, aunque representan un método eficiente y de bajo costo, requiere un amplio trabajo de ingeniería. Las redes neuronales, los controladores difusos y la computación evolutiva representan un método alternativo de solución de problemas de control.

Debido a su característica de aproximador universal de funciones, las redes neuronales permiten realizar controladores que pueden compensar dinámicas indeseadas inclusive sin conocer un modelo exacto de la planta. Los sistemas difusos posibilitan modelar una planta con un escaso conocimiento de la misma y su realización en control es inmediata. La computación evolutiva engloba técnicas de optimización que permiten sintonizar controladores de tipo clásico de una manera más rápida.

El presente artículo pretende demostrar las ventajas y desventajas de algunas técnicas de control inteligente utilizando una planta sencilla de tercer orden SISO con dos perturbaciones y algunas alinealidades, tratando de determinar las dificultades que se puedan encontrar en la aplicación de una u otra técnica. Se encontró que algunos controladores neuronales pueden mejorar significativamente algunas características de estado transitorio; el controlador difuso, gracias a su concepción lingüística muy cercana al razonamiento del experto, fue fácilmente implementado a nivel de simulación y posee esfuerzos e índices de control adecuados. Los controles PID sintonizados evolutivamente presentaron buenos índices de error y de acción de control.

El artículo se encuentra organizado de la siguiente manera: En la sección 2 se describe el modelo del tanque de agitación continua utilizado, en la sección 3 se explica el procedimiento general para obtener los controladores inteligentes, en la sección 4 se muestra los resultados obtenidos con cada controlador, en la




Figura 1. Tanque de Calentamiento con Agitación Continua

sección 5 se estudia el desempeño individual de cada controlador y finalmente en la sección 6 se presentan las conclusiones del trabajo.

2. DESCRIPCIÓN DEL PROBLEMA

La planta utilizada en el presente estudio comparativo corresponde a un tanque de agitación continua (Smith and Corripio, 1991), figura 1. El tanque se utiliza para calentar un flujo en proceso, de manera que se logre una composición uniforme de los componentes previamente mezclados. El control de temperatura es importante, porque con una alta temperatura se tiende a descomponer el producto, mientras que con una temperatura baja la mezcla resulta incompleta. La sustancia contenida en el tanque se calienta por medio del vapor que se condensa en un serpentín. Para controlar la temperatura del tanque se realiza una acción de control sobre la válvula de vapor.

En las condiciones de diseño, el flujo de alimentación $F(t)$ es $7,08 l/s$ a una temperatura $T_i (^{\circ}C)$ de $37,7^{\circ}C$. El contenido del tanque se debe mantener a una temperatura T de $65,5^{\circ}C$. Las posibles perturbaciones son cambios en la tasa de alimentación $F(t)$ y en la temperatura $T_i (^{\circ}C)$.

La válvula de control esta diseñada con una sobrecapacidad del 100 % y las variaciones en la caída de la presión se pueden despreciar. La válvula es de igual porcentaje, con un parámetro de ajuste de rango igual a 50; la constante de tiempo de τ_v del actuador es 12s.

Para este estudio se discretizó el modelo presentado en (Smith and Corripio, 1991) con un periodo de muestreo de 42s. Se consideraron las características dinámicas de los disturbios y no linealidades como la saturación de las entradas y salida, cuantificación de la acción de control en intervalos de 1 %.

3. DISEÑO DE CONTROLADORES INTELIGENTES

Para realizar el diseño y comprobación de los sistemas de control neuronal, difuso y PID sintonizado, se realizaron modelos en Simulink y MATLAB, programas que ofrecen herramientas muy completas para la manipulación de redes neuronales, sistemas de inferencia difusa y algoritmos evolutivos (Demuth and Beale, 2001; MathWorks, 2001).

3.1 Obtención de los modelos neuronales directo e inverso

Gran parte del trabajo en neurocontroladores es la búsqueda de modelos directos y/o inversos del proceso a controlar. La obtención de estos modelos se realiza a partir de un experimento que permite obtener datos que reflejen el comportamiento normal de la planta. Estos datos deben cubrir toda la posible área de trabajo del sistema y además, tener suficientes datos para lograr una mayor precisión de los resultados, al realizar el entrenamiento de la red. También es necesario describir un vector regresor que dependerá de las características dinámicas del sistema. La realización de este experimento puede hacerse en el sitio, por medio de la incursión de un generador de valores aleatorios, si no se posee un modelo matemático de la planta, o durante una simulación, si se posee un modelo preciso de la planta. Para obtener un buen controlador neuronal que satisfaga las características de diseño, el uso de un experimento adecuado es importante (Norgaard *et al.*, 2000).

El experimento realizado utilizó un modelo en Simulink, el cual fue simulado para 11200 unidades de tiempo, con un tiempo de muestreo de 0,7 unidades. La entrada a la válvula corresponde a un generador de números aleatorios entre $[0, 100]$. Las entradas de disturbio se dejaron en su punto de operación.

A partir del conocimiento dinámico de la planta, se describe un regresor para el modelo directo (ecuación 1) y para el modelo inverso (ecuación 2). Estos vectores describen la arquitectura de entradas de la red, aunque ambos modelos poseen una sola salida. Debido a la escala de los datos, es necesario normalizarlos, ya que el uso de datos muy dispersos y de valores superiores a $[-1, 1]$, genera problemas en el entrenamiento de la red. Con base en estas consideraciones, se entrenaron los modelos durante 75 iteraciones utilizando el algoritmo de entrenamiento Levenberg-Marquardt. La aproximación obtenida del modelo directo con respecto a la planta se muestra en la figura 2.

$$y(k) = \begin{bmatrix} y(k-1), y(k-2), y(k-3), \\ u(k-1), u(k-2) \end{bmatrix} \quad (1)$$




Figura 2. Resultados Comparativos entre el modelo neuronal y la planta

$$u(k) = \begin{bmatrix} r(k), \\ y(k-1), y(k-2), y(k-3), \\ u(k-1), u(k-2) \end{bmatrix} \quad (2)$$

La obtención de un modelo neuronal directo de la planta permite la realización experimentos y simulaciones reemplazando el modelo matemático si este no está disponible. El modelo inverso servirá para compensar las características de un sistema para hacer su respuesta en lazo cerrado equivalente a un retardo.

3.2 Descripción del sistema de inferencia difusa

A partir del conocimiento empírico de la planta obtenido de la observación de los experimentos realizados para extraer los datos de entrenamiento, se diseñó un sistema de inferencia difusa con entradas de error y realimentación, y salida incremental. Se describieron tres conjuntos difusos normalizados de tipo triangular en el intervalo $[-1, 1]$. Para la entrada correspondiente al error se escogieron las etiquetas: Muy Caliente (MC), error muy negativo; Caliente (C), error negativo; Apropriad (OK), Error cero; Fría (F), Error positivo y Muy Fría (MF), Error muy positivo. Para la entrada correspondiente a la derivada se escogieron las etiquetas: Decrecimiento Fuerte (DF), se esta enfriando rápidamente; Decrecimiento (D), se esta enfriando lentamente; Estable (E), se mantiene en un nivel; Crecimiento (C), se esta calentando lentamente y Crecimiento Fuerte (CF), se esta calentando rápidamente. Finalmente para la salida, se escogieron las etiquetas: Cerrar Mucho (CM), Cerrar (C), No Actuar (Q), Abrir (A) y Abrir Mucho (AM). La tabla 1 muestra la base de reglas implementada en el sistema de inferencia difusa.

		Derivada de la salida				
		DF	D	E	C	CF
Error	MC	CP	CP	CM	CM	CM
	C	Q	Q	CP	CP	CM
	OK	AP	AP	Q	CP	CP
	F	AM	AP	AP	Q	Q
	MF	AM	AM	AM	AP	AP

Tabla 1. Base de reglas del sistema de inferencia difusa

3.3 Sintonización de un controlador PID por métodos evolutivos

Los controles PID son los más utilizados en la industria, de hecho cerca del 95 % de los lazos de control poseen controladores PID y la mayoría son PI (Herrero *et al.*, 2002). También existen muchas técnicas para sintonizarlos, entre ellas están:

- Métodos empíricos como el de Ziegler–Nichols.
- Métodos analíticos como los basados en el lugar geométrico de las raíces.
- Métodos basados en optimización, donde se busca minimizar un índice como el IAE.

Sintonizar PID por métodos evolutivos no es algo nuevo. Se ha utilizado en particular los Algoritmos Genéticos en varios trabajos para sintonizar controladores en sistemas no lineales (Herrero *et al.*, 2002; Griffin, 2003). Para este estudio comparativo, se utilizará un Algoritmo Genético (*Genetic Algorithm - GA*) y un Algoritmo de Optimización por Colonia de Hormigas (*Ant Colony Optimization - ACO*) para espacios continuos (Yan-jun and Tie-jun, 2003) como métodos de optimización. La función de costo de los algoritmos esta definida como la ecuación 3 donde $K_1 = 1/N$, $K_2 = 1/(N-1)$, J_1 es el error cuadrático medio (ecuación 4) y J_6 el índice de suavidad de la acción de control (ecuación 9).

$$J_i = K_1 \cdot J_1 + K_2 \cdot J_6 \quad (3)$$

4. RESULTADOS

Para el análisis comparativo se llevaron a cabo cinco experimentos durante 14000 unidades de tiempo, de los cuales se obtuvieron 20000 muestras cada caso. El primero corresponde al trabajo en el punto de operación del sistema con disturbios de flujo y temperatura; los otros experimentos corresponden al seguimiento de referencia sin disturbios, con disturbio de flujo, con disturbio de temperatura y con ambos disturbios. Las señales para los experimentos de seguimiento de referencia son las mostradas en la figura 3.

Se utilizaron tres tipos de neurocontroladores: Control por Modelo Interno (*Internal Model Control - IMC*), Control por Linealización de la Realimentación (*Feed-back Linearization Control - FLC*) y el Control Predictivo Neuronal (*Neural Predictive Control - NPC*). Todos estos modelos están descritos en (Norgaard *et al.*, 2000) y utilizan modelos neuronales de manera directa (IMC y FLC) e indirecta (NPC). Un esquema directo utiliza la red neuronal como controlador, mientras que un esquema indirecto usa la red neuronal como modelo para sintonizar un controlador. La figuras 4, 5 y 6 muestran los resultados obtenidos en el quinto experimento para el IMC, FLC y NPC respectivamente.

El Controlador difuso empleado se diseñó a partir del sistema de inferencia descrito en la sección 3.2. Adi-




Figura 3. Señales para los experimentos. (a – superior) Señal de referencia. (b – medio) Disturbio de flujo. (c – inferior) Disturbio de temperatura.




Figura 4. Resultados del controlador por modelo interno




Figura 5. Resultados del controlador por linealización de la realimentación

cionalmente, se utilizaron ganancias de escalamiento para las señales de entrada y salida (Passino and Yurkovich, 1998) de 0,005 para el error, 0,02 para la derivada de la realimentación y de 95 para la acción de control. La figura 7 muestra el resultado obtenido en el quinto experimento para este controlador.

El controlador PID utilizado es un controlador digital con la estructura $U(z) = K_p \cdot E(z) + K_d(1 - z^{-1}) \cdot$




Figura 6. Resultados del controlador predictivo neuronal




Figura 7. Resultados del controlador difuso




Figura 8. Resultados del controlador PID sintonizado por Algoritmos Genéticos

$E(z) + K_i(1/z - 1) \cdot E(z)$. Los resultados obtenidos con este controlador durante el quinto experimento, se muestran en la figura 8 para algoritmos genéticos ($K_p = 1,0068$, $K_d = 0,0098$ y $K_i = 0,2248$) y en la figura 9 para colonia de hormigas ($K_p = 1,2903$, $K_d = 0$ y $K_i = 0,1955$).

El Controlador *Feedforward* (FFC) se puede considerar como un esquema híbrido, en el cual un controlador convencional, en este caso un PID sintonizado por ACO, junto a un controlador por modelo inverso




Figura 9. Resultados del controlador PID sintonizado por Colonia de Hormigas




Figura 10. Resultados del controlador *Feedforward* (Norgaard *et al.*, 2000). Este esquema pretende solventar las deficiencias de los controladores independientes, al obtener una acción de control cooperativa entre ambos. La figura 10 muestra el resultado obtenido en el quinto experimento para este controlador.

5. ANÁLISIS DE DESEMPEÑO DE LOS CONTROLADORES INTELIGENTES

Para evaluar el desempeño de cada uno de los controladores, es necesario tener datos cuantitativos para su comparación. Se seleccionaron los siguientes parámetros comparativos para representar las ventajas y desventajas de cada uno de los controladores (Cardona, 2004):

1. **Índices de desempeño de error:** Evalúan la diferencia entre el valor deseado y el valor obtenido en la salida. Se definen cuatro índices, el **Promedio del Error al Cuadrado** (ecuación 4), el **Promedio del Error Absoluto** (ecuación 5), el **Promedio del Error al Cuadrado por el Tiempo** (ecuación 6) y el **Promedio del Error Absoluto por el Tiempo** (ecuación 7).

$$J_1 = \frac{1}{N} \sum_{k=0}^N (r(k) - y(k))^2 \quad (4)$$

$$J_2 = \frac{1}{N} \sum_{k=0}^N |r(k) - y(k)| \quad (5)$$

$$J_3 = \frac{T^2}{N} \sum_{k=0}^N k \cdot (r(k) - y(k))^2 \quad (6)$$

$$J_4 = \frac{T^2}{N} \sum_{k=0}^N k \cdot |r(k) - y(k)| \quad (7)$$

2. **Índice de esfuerzo de control:** Evalúa el promedio del valor absoluto de la acción de control (ecuación 8).

$$J_5 = \frac{1}{N} \sum_{k=0}^N |u(k)| \quad (8)$$

3. **Índice de suavidad en el esfuerzo de control:** Compara la diferencia entre una muestra anterior de la señal de control y la actual (ecuación 9). Permite conocer que tan bruscos son los cambios de la señal de control.

$$J_6 = \frac{1}{N-1} \sum_{k=1}^N (u(k) - u(k-1))^2 \quad (9)$$

Luego de realizados los experimentos, se organizaron los resultados, con el fin de presentar una serie de gráficas de barras acumulativas con cada índice. Este tipo de gráfica fue seleccionada, ya que además de permitir una visión individual de cada experimento en cada índice, también permite ver una visión general del controlador. La gráfica correspondiente a la suavidad del índice de control se normalizó entre [0 1]. Ya que en este caso, las gráficas tienen la misma longitud, es necesario establecer el valor correspondiente a cada sección. Los valores de este índice en cada experimento se muestran en la tabla 2. Los resultados totales se pueden ver en las graficas 11, 12 y 13.

6. CONCLUSIONES

En este artículo se estudiaron siete técnicas de control basadas en inteligencia computacional. Se pudo observar que los controladores neuronales disponibles en MATLAB como bloques de Simulink se comportaron de una manera inferior a los controladores neuronales implementados directamente, además de presentar una mayor carga computacional. Cabe anotar, que si bien

	1	2	3	4	5
IMC	89.50	69.15	70.18	64.87	65.62
FFC	43.13	47.42	47.39	47.58	47.62
FLC	4119	3732	3766	3915	3822
NPC	0.65	1.97	1.93	1.96	1.96
FC	0.15	0.57	0.57	0.58	0.58
PIDAG	0.06	1.03	1.03	1.02	1.03
PIDACO	0.04	1.32	1.32	1.32	1.32

Tabla 2. Valor del índice de suavidad de la acción de control J_6 .

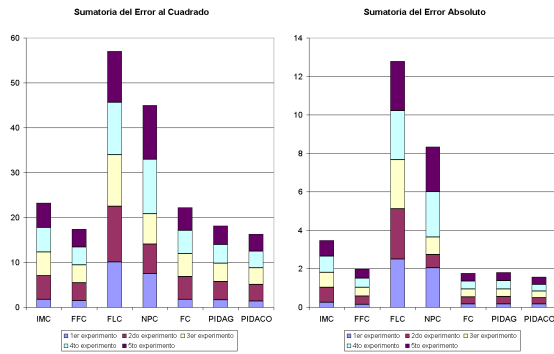


Figura 11. Índices de desempeño: (a - izquierda) Sumatoria del Error Cuadrado (b - izquierda) Sumatoria del Error Absoluto

el control predictivo tuvo una señal de control adecuada, su comportamiento frente a las perturbaciones en los experimentos fue pobre. El control por linealización de la realimentación fue el controlador con menor desempeño entre los probados. Los esquemas neuronales directos como el modelo interno y control *feedforward*, pese a que mejoran sustancialmente la velocidad de respuesta, poseen esfuerzos dañinos para un actuador real. La adición de un filtro de segundo orden con una característica dinámica deseada es una solución para disminuir los sobrepasos. Otro problema observado se refiere a las oscilaciones de baja amplitud presentes en el sistema que representan problemas de estabilidad en el controlador.

Los controladores PID y Difuso obtuvieron los mejores desempeños, tanto en error como en esfuerzo de control, presentando buenas respuestas en estado transitorio y estable. Para el caso del controlador difuso, una buena selección de reglas y constantes de escalamiento, permitió la obtención de un buen desempeño. Adicionalmente, se destaca el comportamiento del control sintonizado por ACO, ya que este obtiene el mejor desempeño en las pruebas realizadas.

Un trabajo futuro incluirá mayor experimentación en el uso de algoritmos de inteligencia de enjambres para el control de sistemas, en particular su uso en




Figura 12. Índices de desempeño: (a - izquierda) Sumatoria del Error Cuadrado por el Tiempo (b - izquierda) Sumatoria del Error Absoluto por el Tiempo

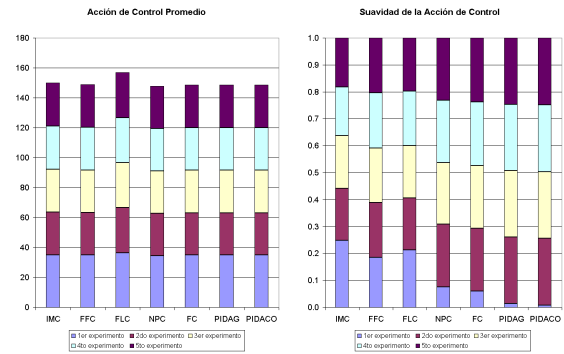


Figura 13. Índices de desempeño: (a - izquierda) Acción de Control Promedio (b - izquierda) Suavidad de la Acción de Control

controladores adaptativos para sistemas multivariable y con fuertes alinealidades.

AGRADECIMIENTOS

Este trabajo ha sido parcialmente financiado por Colciencias y la Universidad del Valle, a través de una beca de investigación otorgada a Mario A. Muñoz a través del proyecto “Plataforma de Procesamiento Distribuido, con Acceso Remoto Multiusuario y Emulación de Sistemas Dinámicos, para la Investigación y Educación en Ingeniería”, contrato No. 1106–11–17707.

REFERENCIAS

- Cardona, J. (2004). Control inteligente en un entorno de instrumentación virtual. Master's thesis. Universidad del Valle.
- Demuth, H. and M. Beale (2001). Neural network toolbox for use with matlab.
- Griffin, I. (2003). On-line pid controller tuning using genetic algorithms. Master's thesis.
- Herrero, J. M., X. Blasco, M. Martínez and J. V. Salcedo (2002). Optimal pid tuning with genetic algorithms for non linear process models. In: *IFAC 15th Triennial World Congress*.
- MathWorks, The (2001). Fuzzy logic toolbox for use with matlab – version 2.0.
- Norgaard, M., O. Ravn, N. K. Poulsen and L. K. Hansen (2000). *Neural Networks for Modelling and Control of Dynamic Systems*. Springer.
- Passino, K. and S. Yurkovich (1998). *Fuzzy Control*. Addison-Wesley Longman, Inc.
- Smith, C. A. and A. B. Corripio (1991). *Control Automático de procesos – Teoría y Practica*. Noriega Editores.
- Yan-jun, L. and W. Tie-jun (2003). An adaptative ant colony system algorithm for continuous-space optimization problems. *Journal of Zhejiang University SCIENCE* 4(1), 40–46.